



江苏科技大学

本科毕业设计论文

基于集成学习的电信客户流失预测系统的
研究和设计

学 院 _____ 自动化学院

专 业 _____ 自动化

学生姓名 _____ 陈科举

班级学号 _____ 222210301107

指导教师 _____ 暴琳

2026 年 5 月

摘要

如今，数字经济发展得很快，电信行业的市场竞争情况也出现了明显改变，行业发展的重心已经从原来的扩张用户数量，慢慢转到了对存量用户做运营和挖掘价值上，客户流失已经成了影响运营商持续发展的关键问题，数据表明，运营商拉新用户的成本，是维护已有用户成本的 5 到 10 倍，用户流失率每降 1 个百分点，企业净利润就能提高 3%-5%，看得出来留住用户对运营商的盈利情况还有市场竞争力影响都很大。过去靠人工经验判断用户是否会流失的方法，存在反应慢、能覆盖的用户少、预测不准等问题，已经没法满足现在精细化运营的要求，所以需要搭建一套科学高效的客户流失预测体系，给运营商制定留存用户的策略给出参考依据。

针对电信客户流失预测里存在的数据维度杂、样本不平衡、传统模型适配能力不够这些实际问题，本文以真实的电信业务数据为基础，结合集成学习算法，设计出了一套完整的客户流失预测方案。在处理原始数据的阶段，主要做了缺失值补全、去掉异常数据、给分类特征做编码这几项工作，保证输入模型的数据符合规范可以使用，同时结合电信业务的实际场景特点，搭建出三类核心的衍生特征：从用户行为按时间排列的数据得到的时序特征、围绕业务风险识别得到的风险特征，还有从用户历史数据整理得到的用户画像特征。借助对特征的处理优化，模型描述用户流失行为的能力得到了进一步提高，为了让实验结果可以重复得到，本次研究用分层抽样的方法拆分训练集和验证集，还严格保证两个数据集的数据分布保持一致。

建立模型和验证性能的环节，本文选了传统机器学习模型和集成学习模型做对比，传统模型包括逻辑回归、随机森林、支持向量机、GBDT；集成学习模型包括 XGBoost、LightGBM、CatBoost，所有模型都用统一的训练步骤和超参数设置，保证实验结果可以互相比较。多个模型对比性能后发现，集成学习模型的预测效果比传统机器学习模型更好，其中 XGBoost 的表现最突出——它在验证集上的 AUC 值和准确率都是所有模型里最高的，能高效识别出高流失风险的用户，预测结果稳定，泛化能力也不错，这套预测方案可以直接用到电信运营商的客户留存工作里，给运营商提供数据支撑，帮助运营商把应对方式从被动等用户流失，改成主动防控、精准挽留，切实提高高流失风险用户的挽留效率。

关键词：电信客户流失预测；集成学习；特征工程；XGBoost

Abstract

Nowadays, the digital economy is developing rapidly, and the market competition in the telecommunications industry has also changed significantly. The focus of industry development has gradually shifted from the original expansion of the number of users to the operation and mining value of the stock users. Customer churn has become a key issue affecting the sustainable development of operators. The data shows that the cost of operators pulling new users is 5 to 10 times the cost of maintaining existing users. For every 1 percentage point of user churn rate, the net profit of enterprises can increase by 3 % -5 %. It can be seen that retaining users has a great impact on the profitability of operators and market competitiveness. In the past, the method of judging whether users will be lost by manual experience has problems such as slow response, few users that can be covered, and inaccurate prediction. It has been unable to meet the requirements of current refined operations. Therefore, it is necessary to build a scientific and efficient user churn prediction system to provide reference for operators to formulate strategies for retaining users.

Aiming at the practical problems of data dimension, sample imbalance and insufficient adaptation ability of traditional models in telecom customer churn prediction, this paper designs a complete set of customer churn prediction scheme based on real telecom business data and integrated learning algorithm. In the stage of processing the original data, the main work is to complete the missing values, remove the abnormal data, and encode the classification features to ensure that the data of the input model can be used in accordance with the specifications. At the same time, combined with the actual scene characteristics of the telecommunications business, three core derivative features are built: the time series features obtained from the data of the user's behavior arranged by time, the risk characteristics obtained around the business risk identification, and the user portrait features obtained from the user's historical data. With the help of feature processing optimization, the model's ability to describe user churn behavior has been further improved. In order to make the experimental results repeatable, this study uses a stratified sampling method to split the training set and the verification set, and also strictly ensures that the data distribution of the two data sets is consistent.

In the process of establishing the model and verifying the performance, this paper selects the traditional machine learning model and the integrated learning model for comparison. The traditional models include logistic regression, random forest, support vector machine and GBDT. The integrated learning model includes XGBoost, LightGBM, and CatBoost. All models use unified training steps and hyperparameters to ensure

e that the experimental results can be compared with each other. After comparing the performance of multiple models, it is found that the prediction effect of the integrated learning model is better than that of the traditional machine learning model. Among them, XGBoost has the most prominent performance. Its AUC value and accuracy on the verification set are the highest in all models, and it can efficiently identify users with high loss risk. The prediction results are stable and the generalization ability is good. This prediction scheme can be directly used in the customer retention work of telecom operators, providing data support for operators, helping operators to change their coping methods from passive users to active prevention and control, accurate retention, and effectively improving the retention efficiency of users with high loss risk.

Key words: telecom customer churn prediction; ensemble learning; feature engineering; XGBoost

目 录

摘要	2
Abstract.....	3
第 1 章.绪论.....	7
1.1 研究背景与意义.....	7
1.1.1 研究背景.....	7
1.1.2 研究意义.....	8
1.2 国内外研究现状.....	9
1.2.1 数据预处理与特征工程研究现状.....	9
1.2.2 预测模型构建与优化研究现状.....	11
1.3 本文结构.....	13
第 2 章.相关理论与技术基础	15
2.1 电信客户流失预测问题.....	15
2.2 机器学习算法.....	16
2.2.1 传统机器学习.....	16
2.2.2 集成学习.....	21
2.4 本章小结.....	24
第 3 章.基于集成学习的电信客户流失预测模型设计	25
3.1 模型整体架构.....	25
3.1.1 所提模型框架.....	25
3.1.2 各模块核心功能.....	26
3.2 传统机器学习模型分支设计.....	26
3.2.1 逻辑回归模型.....	26
3.2.2 支持向量机模型.....	27
3.2.3 随机森林模型.....	27
3.2.4 梯度提升树模型.....	27
3.3 集成学习模型分支设计.....	27
3.3.1 XGBoost 模型.....	28
3.3.2 LightGBM 模型.....	28
3.3.3 CatBoost 模型.....	28
3.4 模型训练与验证流程.....	29
3.4.1 配置加载与数据校验.....	29
3.4.2 模型初始化与数据划分.....	30
3.4.3 模型训练与早停机制.....	30
3.4.4 结果输出.....	30
3.5 本章小结.....	30
第 4 章.实验结果与分析.....	32
4.1 实验环境与模型参数配置.....	32
4.1.1 实验环境.....	32
4.1.2 模型超参数配置.....	32
4.2 模型评估指标.....	33
4.2.1 混淆矩阵.....	33
4.2.2 ROC 曲线与 <i>AUC</i> 值.....	34
4.3 数据预处理和特征工程.....	35
4.3.1 数据集说明及数据预处理.....	35
4.3.2 特征工程构建与特征分析.....	36
4.4 实验结果对比分析.....	40
4.4.1 传统机器学习基线模型结果分析.....	40
4.4.2 集成学习基线模型结果分析.....	错误!未定义书签。

4.4.3 三类高性能梯度提升模型结果分析	42
4.4.4 多模型综合对比分析	43
4.5 本章小结	44
第 5 章.结论与展望.....	45
5.1 结论	45
5.2 研究不足与未来展望	45
参考文献	47
致谢	50

第1章.绪论

1.1 研究背景与意义

1.1.1 研究背景

在数字经济更新速度越来越快、数字中国战略不断推进的现在，数字相关基础设施建设正在持续完善。电信行业作为撑住数字经济发展的核心载体，行业定位已经从传统的通信服务提供商，慢慢转成了数字服务综合运营商，要承担保障通信顺畅、帮各个行业做数字化转型的重要责任，同时，电信行业的市场竞争格局也发生了根本性变化，竞争越来越激烈，传统的市场竞争方式已经很难跟上行业发展的需要。现在的电信市场，不光要面对中国移动、中国联通、中国电信三家传统运营商之间抢存量用户的博弈——每家都推出了不一样的资费套餐、增值服务，争抢有限的存量用户资源；还要面对互联网企业跨界进来带来的冲击，各类互联网公司靠着自己的技术优势和用户基础，推出网络电话、流量套餐、物联网服务这类业务，进一步分走了传统电信运营商的用户群体，用户能选的范围也就大了很多。

跟着通信行业慢慢成熟，携号转网政策也全面推开了，用户换运营商的门槛降了特别多，流动性明显变强，忠诚度跟着也下降了，这就让电信运营商的用户流失问题变得更严重。对运营商来说，用户是最核心的无形资产，也是赚钱和长期发展的基础，用户流失不光直接让通信业务收入往下掉、市场份额变小，还会提高运营成本——重新拉新用户要砸进去很多营销、推广和服务的钱，留住老用户的成本要低不少。

根据艾瑞咨询、易观分析这类机构给出的相关报告估算，电信运营商拉一个新用户的综合成本（包括营销推广、渠道搭建、用户激活这些部分）加起来，大概是留住一个老用户成本的5到10倍，部分细分市场这个倍数还要更高，行业里长期攒下来的运营经验表明，用户流失率每降1个百分点，企业净利润就能提高3%到5%，现在存量竞争越来越激烈，这个比例给运营商盈利带来的提高效果就更明显了，目前国内电信行业月均用户流失率保持在1.5%到3%之间，看起来比例不高，但结合咱们国家庞大的电信用户基数来看，每个月流失的用户数量还是不小的。长期攒下来，会对运营商的营收稳定性和市场竞争力造成很严重的影响，所以，管控存量用户流失已经变成各大电信运营商日常运营管理里的主要工作，也是现在必须解决的关键问题。

现在，跟着大数据和人工智能技术的快速发展，电信运营商经过长期运营已经攒下了海量的用户数据。数据覆盖了好多方面：用户基本信息（性别、年龄、所在地区、套餐类型等等）、消费行为数据（每个月消费金额、交话费的方式、订购增值服务的情况等等）、通信行为数据（通话时长、通话频率、发短信的数量、流量使用的时间段和用量等等），还有用户跟客服的交互记录、投诉记录、办理业务的记录等等。这些数据里藏着很多用户行为规律和流失隐患信息，是运营商做用户流失预测、做到精准运营的重要基础。

但是现在大部分电信运营商，对这些数据的挖掘和利用程度还是比较低，数据本身的价值没能完全发挥出来。在预判用户会不会流失这一块，传统方法

基本都是靠着一线运营人员的个人经验来判断——只靠片面的了解加上主观想法，来找出可能会流失的用户，这种方法存在很明显的不足：第一点是反应太慢，往往都得等用户表现出很明显的流失倾向之后才能发现，没法提前预判；第二点是准确率不高，全靠主观经验没有数据支撑，很容易出现错判、漏判的情况，第三点是能覆盖的范围不够大，做不到对大规模用户做全面排查，满足不了精细化、规模化挽留用户的实际要求。

1.1.2 研究意义

本次围绕集成学习做的电信用户流失预测研究，不管在补充理论还是实际应用上都有价值，能从学术研究和行业落地两个方向产生积极作用。

从理论层面讲，本研究对电信行业客户关系管理的相关技术体系做了有效补充。电信业务数据一般都有特征维度高、样本分布不均匀、特征类型杂糅这些特点，通用的数据处理方法往往没法完全适配这个行业的专属场景。本研究结合电信业务的实际需求，设计了一套针对性较强、流程完整的数据预处理方案，同时围绕业务逻辑搭建了多类高关联度的衍生特征，这项工作完善了行业精细化数据处理和特征工程设计的内容，给同类型的电信流失预测研究提供了更适配的技术思路，也补上了该场景下部分细化研究的空白，另外，研究选了XGBoost、LightGBM、CatBoost 三种常用的梯度提高集成模型做系统性对比测试，测试各类模型在电信流失预测任务里的适配程度和性能差别，还搭建了以精度、可解释性、运行效率为核心的三维评价体系，这些工作让集成学习算法在电信行业的应用研究内容更丰富，也完善了相关模型在垂直领域的应用体系，除此之外，本研究把特征重要性分析和电信业务规则结合到一起，搭建了模型预测结果、核心流失诱因与业务逻辑之间的对应关系，这在一定程度上减弱了机器学习模型自带的黑盒属性，给流失预测模型可解释性方向的研究提供了新的参考思路。

从实践应用角度讲，本研究得到的成果有比较强的行业落地价值，第一，模型可以比较准确地判断出用户流失概率和风险等级，运营商就能把营销补贴、专属服务这类有限资源，集中投放到高价值、高风险的用户群体里，减少无差别运营带来的资源浪费，提高资源配置效率，同时也能降低用户流失造成的经济损失，省下开发新用户的成本，优化企业整体的运营成本结构。第二，提前识别潜在流失用户，再落实针对性的挽留措施，可以有效拉长用户的在网时长，充分挖掘存量用户的长期价值，还能带动套餐升级、订购增值业务这类二次消费，直接帮运营商提高营收和整体盈利水平，第三，利用模型解析出用户流失的关键影响因素，就能给业务优化提供数据支撑，比如针对性调整套餐的流量配置、定价和权益结构，优化客服投诉的处理流程，让业务迭代变得更精准高效，在现在存量竞争越来越激烈的市场环境里，一套精准的流失预测体系能帮助稳固客户基本盘，提高用户满意度和忠诚度，形成“精准挽留—体验优化—客户留存—价值提高”的良性循环，帮运营商在同业竞争和跨界冲击里打造出差异化优势。同时，本研究还能促进电信运营方式的转型升级，让行业从传统被动应对流失的管理方式，转成主动预判、精准干预的智能化运营方式，促进客户关系管理往精细化、数字化、智能化方向发展，这跟数字经济背景下电信行业的整体发展趋势是吻合的。

1.2 国内外研究现状

数字经济深度渗透，电信行业存量竞争日趋激烈，客户流失已经成为制约运营商营收稳定、市场竞争力提升的一个核心痛点。据 Chang 等人^[1]统计，全球电信行业年流失率普遍超过 30%。获取一位新用户的成本大约是保留一位老用户的 5 到 8 倍，客户流失直接导致运营商产生巨额的获客成本与营收损失。在此背景下，电信客户流失预测作为客户关系管理（CRM）的核心环节，同时受到学术界和工业界的关注。国内外学者围绕数据预处理、特征工程、模型构建等关键环节，开展了大量实证研究与技术创新。下面重点梳理数据预处理与特征工程、预测模型构建与优化这两个方向的研究现状，为本文提供理论与实践的参考。

1.2.1 数据预处理与特征工程研究现状

电信行业用户数据有几个显著特点：维度高、样本分布不平衡、特征类型复杂、还包含敏感信息。数据预处理与特征工程的质量，直接影响流失预测模型的性能，所以这一直是国内外研究的重点环节。数据预处理方面，核心研究主要集中在缺失值处理、异常值剔除、样本不平衡缓解这三个方向上。学者们结合电信数据自身的特性，提出了多种针对性处理方法^{[2][3][4]}，相关成果也在随时间推移不断优化。

不同阶段的研究，在处理缺失值和异常值时，都会结合数据本身特点用不同的处理方案，整体来看，处理方法从最初的基础处理，慢慢发展成了更精细的优化方式，阿克弘等人^[4]在 2023 年做了一项基于 GAN 数据重构的流失预测研究，研究里先用有效的预处理方法把电信用户流失数据里的脏数据去掉，给之后的数据重构和模型训练打好了质量基础，这项研究把前期预处理和数据重构结合在了一起，补上了之前二者衔接不够的漏洞，胡晓东等^[5]在 2024 年做了基于 XGBoost 的流失预测研究，研究中用标准化的预处理流程去掉异常数据，减少了数据噪声对模型训练的干扰，也让模型预测的稳定性得到了提高。Haridasan 等^[6]在 2025 年做了基于条件变分自编码器（CVAE）的流失预测研究，专门针对文本类数据设计了一套完整的预处理流程，包含分词、词干提取、删除停用词、拼写校正，保证多源异构数据格式统一并且可以正常使用。Asif 等^[3]在 2025 年搭建 XAI-Churn TriBoost 预测模型时，给出了更精细的处理方案：用贝叶斯岭迭代插补法处理缺失值，再结合鲁棒性缩放、标准化与最小-最大缩放组成序列数据缩放方法，保证特征数据的一致性和可靠性。跟之前的研究比，他们这套预处理方法针对性更强，最终处理效果也更好。

样本不平衡是电信客户流失预测里最突出的数据问题之一，流失用户占比一般只有 10%到 15%上下，训练得到的模型很容易偏向非流失用户，最终会让流失用户的识别精度变低，针对此难点，国内外学者的研究一直在推进：从早期传统的过采样，慢慢发展到智能数据重构，平衡效果也在不断提高，Omid 等

[7]在 2023 年讨论了数据平衡和分类器性能之间的互相影响，给出了一套同时兼顾速度和精度的混合分类器方案，给实际应用场景里怎么选数据预处理方案提供了参考。同一年，阿克弘等^[4]提出了基于生成对抗网络（GAN）的数据重构方法，靠生成合成数据来缓解样本不平衡的问题。实验结果表明，跟传统的 SMOTE 采样比起来，这个方法让 XGBoost 模型的准确率升高了 6.75%，召回率升高了 30.91%，同时还解决了传统过采样容易生成噪声的问题，给之前的数据平衡策略做了优化。Hamza 等^[8]在 2024 年提到，流失数据集的偏态分布对预测性能影响比较大，针对这个问题提出了一种基于采样的异构多层堆叠集成方法，把数据平衡和模型融合结合在一起，有效减轻了样本不平衡带来的不好影响。Googerdchi 等^[9]在 2024 年提出的多目标进化集成学习模型里，特意设计了目标函数来处理样本不平衡问题，他们提出的 MOEEC-2 模型拿到了 96.35% 的准确率和 94.89% 的 AUC 值，对流失用户的识别能力提高得很明显，这项工作把数据平衡和模型优化结合得更紧密，研究深度也往前推进了一步。Abdelhady 等^[10]在 2025 年用 SMOTE 算法加类别权重调整的方法，处理占比 14.6% 的流失样本不平衡问题，结合随机森林模型做到了 95.13% 的预测准确率和 0.89 的 AUC 值，也验证了这套平衡策略在实际场景里是有效的。

特征工程这块，研究方向已经慢慢从传统的基础特征提取，转到了贴合电信业务场景的衍生特征搭建，还有特征的筛选优化上面。特征体系越来越丰富，用到的筛选方法也比以前更精准了。在特征构建上，Binh 等^[11]2024 年相关研究选了数据使用量、在网时长、充值情况、跨运营商通信、手机终端共 6 类特征进行分析，发现跨运营商的通信行为，对用户流失有着很明显的影 响，这给和业务场景有关的特征研究补上了新的内容。Kirgiz 等^[12]在 2024 年重点关注 OTT 服务、品牌应用、游戏化忠诚度活动等新型特征的作用，其实证结果说明这类特征对流失预测很重要，丰富了电信流失预测的特征维度，也与行业发展的新趋势比较贴合。Abdelhady 等^[10]2025 年通过特征重要性分析指出，日通话时长、日消费金额与客服通话次数是影响用户流失的几个最关键因素，后续研究做特征筛选时可以以此为参考。Mettle 等^[13]在 2026 年的研究中构建了一个涵盖用户消费、服务使用、套餐适配、客户服务等多个维度的特征集，再结合超参数调优，模型性能得到了进一步提升。与之前的研究相比，他们的特征维度更系统、更全面。

做特征筛选时，已经有不少学者用了各类方法来剔除掉多余的冗余特征，最终都是为了提高模型的运行效率还有泛化能力，筛选特征的方式也在慢慢发生变化，已经从早期简单筛选，慢慢转向更精准、智能化的筛选方式。Ehsani 等^[14]在 2024 年用排列重要性还有 SelectKBest 方法给所有特征排序，从中挑出了预测价值最高的一批特征，这个工作对优化模型起到了实际帮助。Wang 等^[15]同样在 2024 年提出 Maj-LASSO 算法，直接把特征筛选和不平衡数据处理两个步骤结合在一起，这种做法的优点很明确：筛选出关键流失预测因子的同时，还能缓解样本不平衡带来的问题，不仅特征筛选的针对性更强，最终效果

也更好，做到了数据预处理和特征筛选两个环节的协同优化。黄学德等^[16]在 2025 年利用探索性统计分析，筛选出和用户流失关联度高的特征，再配合 XGBoost 模型使用，最终分类效果不错，元振锋等^[17]在 2025 年则先用信息价值法还有相关性分析做初步筛选，之后再结合 TabNet 模型给出的特征重要性评估进一步完善最终的特征集合，这个思路把深度学习模型的特征评估方式加了进来，得到的筛选结果也更准确。Asif 等^[3]在 2025 年采用 Boruta 技术配合随机森林做特征筛选，既可以有效保留那些对流失预测影响比较大的特征，也能减少冗余特征带来的计算负担，在大规模数据集上的表现很不错。

1.2.2 预测模型构建与优化研究现状

构建与优化流失预测模型是电信客户流失研究的核心。国内外学者的研究方向涵盖传统机器学习、集成学习、深度学习、混合模型等，研究大致沿着时间线推进。预测精度、稳定性和模型适配性在逐步提高，工程化落地能力也受到越来越多的关注^{[17][18][19][20]}。整体来看，这个领域的研究脉络比较清楚，是一步步往前走的。

传统机器学习模型结构简单、可解释性强、训练效率高，在电信流失预测中用得比较多。常见的有逻辑回归、决策树、支持向量机（SVM）、朴素贝叶斯等。早期研究主要用单一传统模型，后来转向模型对比和优化。汪明达等^[21]在 2019 年提出了一个混合模型，融合了神经网络、机器学习、朴素随机过采样和投票方法，在 KDD Cup 2009 数据集上做了验证。模型在前 200 名高危流失用户中的预测准确率达到 31.8%，这对后续混合模型的研究有参考作用。田波等^[22]在 2021 年把生存分析方法引入流失预测，用 Cox 模型跟踪用户从入网到流失的整个生命周期。这样做能给用户挽留决策提供比较精确的时间依据，也拓宽了传统模型的应用范围。Omid 等^[7]在 2023 年对比了神经网络、K 近邻、支持向量机、逻辑回归、决策树、随机森林等几种传统分类模型的性能，系统分析了它们在电信流失预测中的适配情况。相比之前只做单一模型的研究，这项工作更有对比性，参考价值也更高。Binh 等^[11]在 2024 年用朴素贝叶斯、J48 决策树、决策表三种算法做流失预测。实验结果显示，决策表算法表现最好，准确率达到 88.8%，传统决策类模型在这个任务上得到了更好的应用。Kirgiz 等^[12]在 2024 年对比了逻辑回归和随机森林的预测性能，最后选了随机森林作为核心模型，这对流失预测和诱因分析有一定帮助。黄学德等^[16]在 2025 年构建了逻辑回归、AdaBoost、XGBoost 等多个传统模型，通过对比验证，发现 XGBoost 在评估流失影响因素时比较稳定，效果也不错。Saleh 等^[18]在 2026 年指出，传统决策树模型虽然简单、容易解释，但容易过拟合，也很难捕捉复杂的特征交互关系。他们提出了一种新的系统森林（SF）分类器，通过系统评估和选择属性来平衡模型的复杂性和可解释性，较好地弥补了传统决策树的缺点，算是传统决策类模型的一个升级。不过，传统单一模型还是有泛化能力不足、处理高

维复杂数据困难、容易过拟合等问题，要满足电信行业精细化的预测需求不太够^{[8][14]}。这也正是后来集成学习和深度学习模型被陆续引入的原因。

集成学习模型把多个基础模型的优势结合起来，预测精度和稳定性都得到了提升。现在它在电信流失预测中是比较主流的研究方向。常见的模型有随机森林、XGBoost、LightGBM、CatBoost 等梯度提升类集成模型，还有投票集成、堆叠集成等融合策略。研究方法也在慢慢变化，从简单的集成逐步转向更精细的集成。Chang 等^[1]在 2024 年用了决策树、提升树、随机森林等几种集成模型做流失预测，其中随机森林表现最好，准确率达到 91.66%，精度 82.2%，召回率 81.8%。他们还结合了可解释性 AI 技术，让模型更贴合业务需求。Googerdchi 等^[9]在 2024 年提出了两个基于聚类的多目标进化集成学习模型（MOEECs），引入了新的多样性度量方式，并针对不平衡数据优化了目标函数。其中 MOEEC-1 模型的准确率达到 97.30%，AUC 值为 93.76%，比传统集成模型要好。Hamza 等^[8]在 2024 年提出了一种基于采样的异构多层堆叠集成方法，把多个基础模型融合在一起，流失预测的精度和稳定性都得到了提高，也给集成模型的构建提供了新思路。胡晓东等^[5]2024 年注意到 XGBoost 算法的超参数比较多，缺少高效的寻优方法，于是用贝叶斯优化、随机搜索、网格搜索三种方法来做超参数调优。实验结果显示，贝叶斯优化后的 XGBoost 模型准确率比另外两种方法好，相比未优化的模型，准确率提高了 4.84%。这说明智能寻优方法确实有优势。Asif 等^[3]在 2025 年把 XGBoost、CatBoost、LightGBM 三个梯度提升模型融合到一起，构建了 XAI-Churn TriBoost 集成模型，用超过 200 万条用户数据做训练，在复杂的电信数据场景下预测表现较好，同时也没有忽略模型的可解释性。Mettle 等^[13]在 2026 年把经过超参数调优的随机森林、XGBoost、逻辑回归模型组合起来，构建了一个软投票集成模型，达到了 85.44% 的准确率、85.48% 的 F1 值和 93.63% 的 ROC-AUC 值，在识别流失用户和非流失用户两方面都做得不错，集成模型的融合策略又往前走了一步。

深度学习模型在电信流失预测中用得也多起来，主要是因为它们特征学得好、非线性拟合能力强。常见的类型有神经网络、LSTM、CVAE、TabNet 等。模型也在演进，从早期简单的神经网络逐渐发展到更复杂的融合结构。Mageshkumar 等^[20]在 2024 年用了神经网络模型，结合多维度用户参数进行训练，流失预测的准确率比较高，说明深度学习在这类任务确实能派上用场。Wang 等^[15]在 2024 年设计了一个 FCLCNN-LSTM 浅层融合深度学习模型，配合 Maj-LASSO 算法做特征筛选。他们通过全连接层平衡特征的重要性，把关键特征被忽略的问题处理得比较好，流失风险评估的准确性因此提高，也让特征筛选和深度学习有了更好的配合。Haridasan 等^[6]在 2025 年提出了基于条件变分自编码器（CVAE）的流失预测方法，结合对比信息提取与生成 Transformer（CGT）来提取特征，再用 t-DSNE 选出合适的特征。这样做之后，流失预测精度和用户服务推荐效果都有所提升。元振锋等^[17]在 2025 年把传统逻辑回归和表格预训练 TabNet 模型融合起来，先用 TabNet 模型做预测，再把预测结果作为新特征来

训练逻辑回归模型。实验结果显示，融合模型的准确率（79.69%）和精确率（77.72%）都高于单一模型，预测精度确实提高了，也实现了深度学习和传统模型之间的优势互补。

混合模型与一些特殊算法的加入，让电信流失预测的研究思路更丰富了。研究方法也在变化，从简单的混合慢慢走向多种技术的融合。张三姐等^[23]在 2023 年把生存分析方法用到了电信客户流失预测上。他们用 KM 模型做组间比较，再用 Cox 风险比例模型分析多个因素对流失时间的影响，从而判断哪些用户可能流失、大概什么时候流失，结果比较准。这也让生存分析方法在流失预测中的应用更成熟了。Shimaa 等^[19]在 2024 年提出了一个混合框架，把数据预处理、集成学习和重采样技术都揉在了一起。流失预测的准确率因此得到提高，也弥补了以往研究没有综合考虑多环节优化的不足，多个技术得到了协同融合。Binh 等^[11]在 2024 年把粗糙集理论应用到电信客户流失预测中，通过规则生成来判断用户的流失倾向。这给传统算法的创新应用提供了一个例子，也让混合模型的算法类型更丰富了。Sana 等^[2]在 2025 年注意到云环境下训练数据有隐私泄露的风险，于是提出了一个带隐私保护的流失预测框架，用生成对抗网络（GANs）和自适应证据权重（aWOE）技术。这样在保证预测精度的同时，用户数据隐私也得到了保护，把电信流失预测的研究范围往外拓展了一些。

总的来看，国内外学者在电信客户流失预测方面做了不少扎实的工作，已经形成了一条从数据预处理到模型构建的完整研究链条。不过，现有研究也还有一些可以改进的地方。比如，不少研究在处理样本不平衡时还是靠传统采样方法，面对极端不平衡的数据效果不够好。再比如，特征体系大多基于截面数据构建，用户行为的时序变化规律没有被充分挖掘出来。另外，模型融合策略也比较单一，不同类型模型的互补优势没能充分发挥。针对这几个问题，本文打算构建一个基于集成学习的电信客户流失预测模型，从优化数据预处理流程、丰富特征体系、改进模型融合策略这几个方向入手，进一步提高流失预测的精度和实用性。

1.3 本文结构

本文一共五章。

第一章是绪论。先讲电信客户流失预测的背景和意义——现在运营商存量竞争激烈，用户流失问题突出，研究的理论和实际价值在哪。然后梳理国内外的研究进展，包括数据预处理、特征工程、模型构建这些方向，还有哪些不足，最后引出本文要做的事。

第二章讲相关理论与技术基础。先界定电信客户流失预测到底是什么问题：样本不平衡、特征维度复杂、精度和可解释性不好兼顾。然后介绍机器学习的基本分类，重点把逻辑回归、支持向量机、随机森林、梯度提升树这几个传统算法的原理和公式说清楚。接着讲 Bagging 和 Boosting 集成学习框架，再

详细分析 XGBoost、LightGBM、CatBoost 三种梯度提升算法的核心机制。这一章就是给后面的模型设计打理论基础。

第三章是模型设计。提出一个整体框架，包含三个模块：数据预处理与特征工程、模型训练与验证、模型指标输出。传统模型选了逻辑回归、SVM、随机森林、GBDT；集成学习选 XGBoost、LightGBM、CatBoost，并且说明了为什么选。最后设计了标准化的训练和验证流程——配置加载、数据划分、早停机制，保证实验结果能复现、对比公平。

第四章是实验结果与分析。先说实验环境和模型超参数配置，接着定义评估指标：混淆矩阵、准确率、精确率、召回率、F1、ROC-AUC。然后对数据做预处理和特征工程，构造了三类衍生特征——时序异动、高风险识别二值特征、用户画像统计特征，再用热力图和特征重要性排序来验证特征是否有用。最后对比七种模型：传统模型选了逻辑回归、SVM、随机森林、GBDT，集成学习选 XGBoost、LightGBM、CatBoost，综合评估后选出了最优的。

第五章是结论与展望。总结本文做了哪些工作、得出的结论——数据预处理、特征工程、XGBoost 模型确实有效。也点出不足，如没处理样本不平衡、没使用时序特征等。后面可以怎么改进：引入过采样、用深度学习模型、加因果推断、搭实际平台做 A/B 测试等等，都进行了展望。

第2章.相关理论与技术基础

2.1 电信客户流失预测问题

电信客户流失就是指用户主动与当前运营商解除服务协议，不再使用其提供的语音通话、手机流量、短信、宽带以及各类增值服务等所有业务，转而选择其他运营商提供的同类服务的行为，也就是我们日常生活中常说的“转网”。需要说明的是，我们这里研究的主要是主动流失行为，也就是用户出于自身意愿主动办理销户或转网手续的情况。而像用户因长期欠费被运营商强制停机销户、或者因个人原因（如出国、去世）被动终止服务的情况，不属于我们的研究范围，因为这类流失行为是运营商无法通过常规挽留手段干预的。

电信客户流失预测，说白了就是一个典型的机器学习二分类问题。它的核心目标非常明确：基于用户过去一段时间内产生的各类历史数据，构建一个能够自动学习用户行为模式的预测模型，然后用这个模型来判断每个用户在未来某一个固定时间段内（通常是1个月或3个月）发生流失行为的概率。在这个二分类任务中，我们会给所有用户打上明确的标签：如果某个用户在我们设定的预测周期内发生了主动流失行为，就将其定义为正样本，标签标注为1；如果用户在预测周期内继续留存使用运营商的服务，没有发生任何流失行为，就将其定义为负样本，标签标注为0。模型通过学习大量历史样本中流失用户和留存用户的行为差异，就能为每个新的用户计算出一个0到1之间的流失概率值，概率越高，说明这个用户未来流失的可能性越大，运营商也就可以优先对这些高风险用户采取挽留措施。

做电信客户流失预测的时候，会遇到三个比较突出的共性问题。这些问题在行业内也比较普遍，直接影响模型的准确性和实际能用程度。首先是样本不平衡，这也是最棘手的一个。电信行业里，绝大多数用户都会继续留着用，真正流失的用户只占很小一部分，通常也就10%到20%左右。样本分布这么偏，模型在训练时自然会偏向占多数的留存用户，优先把留存用户预测准。结果就是，模型的整体准确率看着挺高，但对流失用户的识别能力很差，很多真正会流失的用户都被漏掉了。而对运营商来说，准确找出流失用户比准确认出留存用户重要得多——漏掉一个高价值流失用户带来的损失，远大于误判一个留存用户的成本。

其次是特征维度复杂。电信用户数据的类型很多，有像消费金额、通话时长、流量使用量这种可以直接用数字表示的连续型数值特征，也有像套餐类型、付款方式、性别、是否开通增值服务这种离散的类别特征。不同类型的特征处理方法不一样，数据预处理的难度自然就上去了。更麻烦的是，这些特征之间往往不是简单的线性关系，而是有复杂的非线性交互。举个例子，同样是月消费金额下降，对入网只有一个多月的新用户和入网超过五年的老用户来说，背后的意思可能完全不同。另外，有些特征之间还存在比较强的多重共线性，比如月消费金额和流量使用量、通话时长之间通常相关性很高。要是直接把这些特征塞进模型，不仅计算量会变大，模型的权重也可能不稳定，影响预测结果。

第三个则是模型精度和可解释性的平衡问题。电信客户流失预测最终是为了指导业务实践，运营商不光得知道“哪些用户会流失”，还得知道“这些用户为啥流失”，这样才能制定出有针对性的挽留办法。但机器学习领域里，预测精度和可解释性常常是矛盾的两头：很多预测效果好的模型，比如复杂的集成学习和深度学习模型，属于典型的“黑盒模型”，它们能给出很准的预测结果，却说不太清楚为何会得出这个结果。

2.2 机器学习算法

机器学习属于人工智能的一个主要分支。它的思路不算复杂：让计算机从历史数据里自己学习，找出数据中隐藏的规律和模式，然后用这些规律去预测未知数据或者做决策。按学习方式分，机器学习有监督学习、无监督学习和强化学习三种。其中监督学习用得最多，训练数据都带明确的标签，模型要学的是特征和标签之间的对应关系^[24]。

监督学习下面又分分类和回归两种任务。分类任务是预测样本属于哪个离散类别，回归任务则是预测一个连续的数值。电信客户流失预测这个任务，就是一个典型的二分类监督学习问题——通过算法学习用户特征和流失标签之间的对应关系，来预测用户流失的风险。

在结构化数据的分类任务里，传统单一模型（比如逻辑回归、决策树、支持向量机）结构简单、容易解释，但遇到高维度、非线性、样本不平衡的数据时，泛化能力就有点跟不上了。集成学习算法把多个基学习器的优势凑到一起，既能保证预测精度，又有不错的鲁棒性。现在它在结构化数据分类任务中已经是比较主流的技术方案，也是本研究要用的核心技术。

2.2.1 传统机器学习

2.2.1.1 逻辑回归模型

逻辑回归是二分类任务里的一个经典模型，经常被当作基准来用。它的做法是通过逻辑函数（Sigmoid 函数），如图 2-1 所示，把线性回归输出的连续值映射到 0 到 1 之间，从而得到样本属于正类的概率^[25]。




图 2-1 Sigmoid 函数
Figure 2-1 Sigmoid function

逻辑函数的表达式为：

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (2.1)$$

其中， $z = \mathbf{w}^T \mathbf{x} + b$ 为线性回归的输出； $\mathbf{w} \in \mathbb{R}^d$ 为权重向量，反映各特征对目标变量的影响方向与强度； $b \in \mathbb{R}^d$ 为偏置项； $\mathbf{x} \in \mathbb{R}^d$ 为输入特征向量， d 为特征维度。

将线性输出代入逻辑函数，即可得到样本属于流失类（ $y = 1$ ）的概率：

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (2.2)$$

本研究中， $y = 1$ 表示用户发生主动流失行为， $y = 0$ 表示用户保持在网状态。

为求解最优的模型参数，逻辑回归采用对数似然损失函数作为优化目标，通过最小化该损失函数实现参数估计：

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)] \quad (2.3)$$

其中， n 为训练样本数量， $\hat{y}_i$ 为第 i 个样本的预测流失概率。

逻辑回归结构简单、训练快、也好解释。模型的权重能直接说明每个特征对流失风险的影响方向：权重为正，表示该特征值越大，用户流失风险越高；权重为负则相反。这个特点让逻辑回归不光能当基线模型，给别的模型做性能参照，还能后续的流失原因分析和挽留策略提供一些理论上的依据。

2.2.1.2 支持向量机模型

支持向量机（Support Vector Machine, SVM）是依照统计学习理论设计出的二分类模型，它的主要思路是在特征空间里找出一个最优的分类超平面，让不同类别的样本都能被正确分开，还能让分类间隔做到最大，靠这个办法得到更强的泛化能力^[26]。

对于线性可分的二分类问题，最优分类超平面的表达式为：

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad (2.4)$$

其中， $\mathbf{w}$ 为超平面的法向量，决定超平面的方向； b 为偏置项，决定超平面的位置。

支持向量机的优化目标是最大化分类间隔 $\frac{2}{\|\mathbf{w}\|}$ ，等价于最小化权重向量的L2范数：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad (2.5)$$

约束条件为：

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, n \quad (2.6)$$

其中, $y_i \in \{-1,1\}$ 为样本标签, $\mathbf{x}_i$ 为第 i 个样本的特征向量。

为处理线性不可分数据与噪声样本, 支持向量机引入软间隔机制, 允许部分样本违反约束条件, 同时加入惩罚项控制模型复杂度, 软间隔下的优化目标为:

$$\min_{\mathbf{w}, b, \xi_i} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad (2.7)$$

其中, $C > 0$ 为惩罚系数, 用于平衡分类间隔与误分类样本数量; $\xi_i > 0$ 为松弛变量, 衡量样本违反约束条件的程度^[27]。

对于非线性可分的数据, 支持向量机通过核函数将低维特征空间中的样本映射到高维线性可分的特征空间, 从而有效处理非线性分类问题。本研究采用径向基函数 (Radial Basis Function, RBF) 核, 其表达式为:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (2.8)$$

其中, $\gamma > 0$ 为核函数的带宽参数, 控制映射后样本的分布特性。

支持向量机在高维特征空间里有不错的分类效果, 能很好处理电信用户数据做完特征工程后特征维度偏高的问题, 同时靠核函数就能灵活适配不同种类的数据分布, 给用户流失预测任务给出了靠谱的补充模型。

2.2.1.3 随机森林

随机森林 (Random Forest, RF) 是 Bagging 框架最典型的代表, 如图 2-2 它在决策树基学习器的基础上, 进一步引入了随机特征选择机制, 即每次节点分裂时, 只从所有特征中随机选择一个子集进行最优特征选择^[28]。这种双重随机性使得随机森林的泛化能力进一步提升, 在电信客户流失预测等分类任务中得到了广泛应用。




图 2-2 随机森林算法流程
Figure 2-2 Random Forest algorithm flow

(1) 模型预测函数

分类任务中，最终预测结果由多棵决策树的投票决定：

$$\hat{y} = \text{sign} \left(\frac{1}{K} \sum_{k=1}^K f_k(x) \right) \quad (2.9)$$

其中， K 为决策树数量， $f_k(x)$ 为第 k 棵树的预测结果， $\text{sign}(\cdot)$ 为符号函数，用于输出分类标签。

(2) 节点分裂准则（基尼指数）

单棵决策树的节点分裂采用基尼指数衡量样本纯度，基尼指数越小，节点样本纯度越高：

$$\text{Gini}(D) = 1 - \sum_{i=1}^C p_i^2 \quad (2.10)$$

其中， D 为节点样本集合， p_i 为类别 i 在样本中的占比， C 为类别数。

(3) 节点分裂增益

分裂前后基尼指数的变化为节点分裂增益，随机森林选择增益最大的特征与阈值进行分裂：

$$\Delta \text{Gini} = \text{Gini}(D) - \frac{|D_L|}{|D|} \text{Gini}(D_L) - \frac{|D_R|}{|D|} \text{Gini}(D_R) \quad (2.11)$$

随机森林利用自助抽样以及随机子空间这两种方法，引入了样本和特征的双重随机性，能够有效降低单棵决策树出现过拟合的可能性。不过随机森林本身也存在缺点，它处理高维稀疏数据的能力不够好，而且模型没办法很好地解释结果，很难给出清楚的特征重要性排序。

2.2.1.4 梯度提升树

梯度提升树（Gradient Boosting Decision Tree, GBDT）是 Boosting 串行集成框架的经典实现，以分类回归树（CART）作为基学习器，通过多轮迭代拟合前一轮模型的负梯度（残差），不断累加基学习器的预测结果，最终得到完整的集成模型，是结构化数据分类任务的主流基准算法^[29]。

(1) 模型预测函数

模型的最终预测结果为 K 棵决策树的预测结果累加：

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (2.12)$$

其中， K 为决策树的总数量， $f_k(x_i)$ 为第 k 棵决策树对第 i 个样本的预测结果， $\hat{y}_i$ 为样本的最终预测值。

(2) 梯度提升核心目标函数

GBDT 以梯度下降法为核心优化逻辑，每一轮迭代的优化目标是最小化损失函数，通过拟合损失函数的负梯度来更新模型：

$$Obj = \sum_{i=1}^n l(y_i, \hat{y}_i) \quad (2.13)$$

其中， $l(y_i, \hat{y}_i)$ 为损失函数，二分类任务中通常采用交叉熵损失函数， y_i 为样本真实标签， n 为样本总数。

(3) 负梯度拟合

第 k 轮迭代中，损失函数对当前模型预测值的负梯度（即本轮需要拟合的残差）计算公式为：

$$r_{ik} = - \left[\frac{\partial l(y_i, \hat{y}_i)}{\partial \hat{y}_i} \right]_{\hat{y}_i = \hat{y}_i^{(k-1)}} \quad (2.14)$$

其中， $\hat{y}_i^{(k-1)}$ 是前一轮（第 $k-1$ 轮）迭代完模型给出的预测值。 r_{ik} 就是第 k 轮要拟合的那个负梯度值。

GBDT 是一轮一轮串行着往下做的，每一轮都让模型的偏差小一点。在处理结构化数据的分类问题上，它表现还算稳定。然而传统 GBDT 算法虽然预测精度较高，但存在训练速度慢、内存占用高、易过拟合、需要人工处理类别特征等不足，限制了其在大规模数据集上的应用。

针对传统 GBDT 算法的缺陷，学术界和工业界提出了多种改进算法，其中 XGBoost、LightGBM 和 CatBoost 是目前性能最优、应用最广泛的三种，也是本研究采用的核心算法。

2.2.2 集成学习

集成学习属于机器学习的一种方法，它把多个基础学习器结合在一起，以此得到比单个模型更好的泛化效果，跟单一模型相比，集成学习可以更有效地降低模型的偏差还有方差。碰到非线性、高维度、数据不平衡这类问题时，集成学习的稳定性还有预测准确率都会更高。在目前结构化数据的分类任务里，集成学习算是最常用的技术方案之一^[30]。

按照集成方式的不同，可以分成两大类：一类是 **Bagging**（并行集成），另一类是 **Boosting**（串行集成）^[31]。它们的基本结构如图 2-3 所示。




图 2-3 集成学习两大框架结构

Figure 2-3 Two framework structures of ensemble learning

Bagging 的做法是：用自助采样法（**Bootstrap Sampling**）从原始训练集里有放回地抽多个不同的子集，每个子集独立训练一个基学习器。最后把所有基学习器的预测结果通过投票（分类任务）或平均（回归任务）融合起来，得到最终预测。各个基学习器是并行训练、互不依赖的，所以 **Bagging** 能降低模型的方差，减少过拟合的风险，对数据中的噪声和异常值也不太敏感。

Bagging 是并行集成，**Boosting** 则是串行集成。**Boosting** 的训练方式是迭代的：每轮训练一个基学习器，这个学习器会重点学习前一个学习器预测错的样本，不断修正误差。最后把所有的基学习器加权融合。**Boosting** 能有效降低模型的偏差，对复杂的非线性关系拟合得更准，因此在结构化数据的分类任务里表现通常更好。

2.2.2.1 XGBoost 算法

XGBoost（**EXtreme Gradient Boosting**）是由陈天奇博士提出的一种极端梯度提升算法，属于 **Boosting** 集成框架，被广泛应用于机器学习与数据挖掘竞赛^[32]。在利用二阶导数信息优化目标函数，有效避免过拟合，在不平衡分类任务中表现稳定的同时，**XGBoost** 在 **GBDT** 梯度提升树的基础上引入了正则化项控制模型复杂度^[33]。

(1) 预测函数定义

模型的预测值为多棵决策树预测结果的累加：

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (2.15)$$

其中， K 为决策树数量， f_k 表示第 k 棵树， x_i 为第 i 个样本特征， $\hat{y}_i$ 为样本预测结果。

(2) 带正则项的目标函数

XGBoost 的目标函数同时包含训练误差与模型复杂度两部分：

$$Obj = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (2.16)$$

其中， $l(y_i, \hat{y}_i)$ 为训练误差， $\Omega(f_k)$ 为第 k 棵树的正则项，包含 $L1/L2$ 权重惩罚与叶节点数惩罚，用于控制模型复杂度。

(3) 二阶导数优化目标函数

利用泰勒公式对目标函数进行二阶展开，简化后的形式为：

$$Obj = \sum_{i=1}^n [g_i f_k(x_i) + \frac{1}{2} h_i f_k(x_i)^2] + \Omega(f_k) \quad (2.17)$$

其中， g_i 和 h_i 分别为损失函数的一阶与二阶导数。

(4) 最优叶节点权重

通过对目标函数求导，可得叶节点的最优权重：

$$w_j^* = -\frac{G_j}{H_j + \lambda} \quad (2.18)$$

其中， G_j 和 H_j 分别为叶节点 j 的一阶梯度和二阶梯度之和， λ 为 $L2$ 正则项系数。

(5) 节点分裂增益公式

XGBoost 采用分裂增益公式选择最优分割点，通过最大化分裂前后的目标函数变化来确定分裂方式：

$$Gain = \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} - \gamma \quad (2.19)$$

式中， γ 是预剪枝参数，主要用来控制树的复杂程度。

XGBoost 算法，会同时用上一阶导数和二阶导数的信息。这样有两个好处：一是梯度下降能更快，二是优化精度也能提上去。另外，它的目标函数和损失函数是解耦的，也就是说能用在分类问题上，也能用在回归问题上。所以，像电信用户流失预测这种数据不平衡的分类任务，XGBoost 跑出来的效果还挺稳定的。

2.2.2.2 LightGBM 算法

LightGBM 是在 GBDT 基础上改进出来的一个版本，跑起来更快。它主要用了两个办法：一个是直方图分箱，一个是按叶子生长^[34]。这两个东西让训练效率高了不少。另外，它还加了梯度单边采样和互斥特征捆绑这两种技术。这样做的好处是：模型精度没怎么降，但计算量小了很多。所以，如果电信用户数据集比较大，用 LightGBM 来训练是比较合适的。




图 2-4 直方图算法

Figure 2-4 Histogram algorithm

(1) 直方图分箱特征离散化

将连续特征划分为 b 个区间，每个区间内的梯度统计值为：

$$G_j = \sum_{i \in \text{bin}_j} g_i, H_j = \sum_{i \in \text{bin}_j} h_i \quad (2.20)$$

其中， g_i 和 h_i 分别为损失函数的一阶与二阶导数。直方图分箱减少了计算复杂度，同时降低了噪声对模型的影响。

(2) 按叶子生长的节点分裂增益

LightGBM 每次选择增益最大的叶子进行分裂，而非按层生长，分裂增益公式为：

$$\text{Gain} = \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \quad (2.21)$$

按叶子生长策略能够优先分裂对模型精度提升最大的节点，提升模型训练效率。

(3) 梯度单边采样 (GOSS)

通过保留大梯度样本、随机采样小梯度样本，在不损失模型精度的前提下加速训练过程：

$$a = \frac{\sum_{i \in A} g_i}{\sum_{i \in A \cup B} g_i} \quad (2.22)$$

其中， A 为大梯度样本集合， B 为小梯度样本集合， a 为采样权重系数。

2.2.2.3 CatBoost 算法

CatBoost 是专门针对类别特征做了优化的 Boosting 算法，核心在于有序目标编码和对称树结构，能有效处理电信用户流失数据里的类别特征，还可以避免出现目标泄露的问题，提高模型的泛化能力^[35]。

(1) 类别特征的有序目标编码

避免目标泄露的类别特征编码方式为：

$$\text{CTR}(x_i^c) = \frac{\sum_{j \in D_i^c} y_j + \alpha p}{\sum_{j \in D_i^c} 1 + \alpha} \quad (2.23)$$

其中， x_i^c 为类别特征值， D_i^c 为类别特征的样本集合， p 为全局目标均值， α 为平滑系数。

(2) 梯度提升目标函数

CatBoost 的目标函数形式为：

$$\text{Obj} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \Omega(f_k) \quad (2.24)$$

其中， $l(y_i, \hat{y}_i)$ 为训练误差， $\Omega(f_k)$ 为模型复杂度正则项。

(3) 叶节点最优权重

通过对目标函数求导，可得叶节点的最优权重：

$$w_j = \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (2.25)$$

其中， I_j 为叶节点 j 的样本集合， g_i 和 h_i 分别为损失函数的一阶与二阶导数。

2.3 本章小结

本章先把研究边界和核心问题定下来了。明确把主动流失作为研究范围，也说明了电信客户流失预测在本质上属于二分类监督学习任务。接着梳理了模型训练要用到的四大类用户数据，然后分析了这个领域里三个比较普遍的难点：样本分布不平衡、特征维度复杂且有非线性交互、精度和可解释性不好兼顾。后面介绍了相关机器学习算法的基本原理。先讲了机器学习的基本分类，点明本研究用监督学习。然后详细说明了逻辑回归、支持向量机、随机森林、梯度提升树这四种传统基准模型的数学表达和主要特点，这些就是本研究的对比模型基础。在此基础上，重点讲了集成学习的基本思想，以及 Bagging 和 Boosting 这两个核心框架，还深入分析了 XGBoost、LightGBM、CatBoost 三种改进型梯度提升算法的核心机制。这一章整理的理论基础和算法原理，就是第 3 章模型架构设计和第 4 章实验验证的理论支撑。

第3章.基于集成学习的电信客户流失预测模型设计

为构建高精度、高鲁棒性的电信客户流失预测模型，本章基于机器学习分类算法的理论基础，结合电信客户流失预测的业务特性，设计了一套包含传统机器学习模型与集成学习模型的多模型对比预测框架。该框架通过标准化的模块划分和统一的训练验证流程，能够全面对比不同算法在电信流失预测任务中的性能表现，筛选出最适合该任务的最优模型。本章将详细阐述模型的整体架构、各模块的设计思路、模型选择依据以及通用的训练验证流程，为后续的实验验证提供清晰的技术路线。

3.1 模型整体架构

3.1.1 所提模型框架

本研究把电信客户流失预测模型分成了三个模块，各模块独立但又相互关联，从数据输入到结果输出依次为：数据预处理与特征工程模块、模型训练与验证模块、模型指标输出模块。每个模块有明确的分工，模块之间通过标准化的数据接口传递信息，完成从原始用户数据到最终流失预测结果的整个处理流程。模型整体框架如图 3-1 所示。




图 3-1 模型框架

Figure 3-1 Model framework

3.1.2 各模块核心功能

(1) 数据预处理与特征工程模块

模型的前置处理模块，把原始用户数据转成模型能认的标准化特征矩阵。先做基础的数据清洗：数值型特征用中位数填充缺失值，类别型特征用众数填充。然后通过标签编码把非数值的类别特征统一转成数值格式。在此基础上，还会构建一些能反映用户行为变化趋势和流失风险的衍生特征。最后生成标准化和非标准化两份特征矩阵，分别适配不同模型的输入要求。同时输出特征相关性分析的热力图，把特征之间的关联关系直观展示出来，方便后续筛选特征和优化模型。

(2) 模型训练与验证模块

是整个预测框架的核心部分，负责建模型并评估它的泛化能力。模块里有两个并行的训练分支：传统机器学习和集成学习，分别用标准化和非标准化特征矩阵训练多种分类算法。所有模型都用同一套验证机制做性能评估，保证不同算法之间的对比结果可比较。对于支持迭代训练的梯度提升模型，会引入早停机制，在模型精度和训练效率之间做个平衡，防止训练集上出现过拟合。

(3) 模型指标输出模块

模型结果的汇总和分析部分，统一输出所有模型的训练和验证结果，并从多个维度做横向对比。模块会保存每个模型的预测标签、用户流失概率、最优训练参数、特征重要性排名以及各项核心性能指标。然后通过综合对比，选出在电信客户流失预测任务中表现最好的模型，同时生成模型性能对比表和可视化对比图，把不同算法的优劣差异摆出来。

3.2 传统机器学习模型分支设计

传统机器学习算法是机器学习领域的基础，它们结构简单、训练速度快、也容易解释，常被当作分类模型的基准方法。本研究选了四种有代表性的传统算法作为对比模型，用来衡量集成学习模型在电信客户流失预测任务中能提升多少性能，同时为选哪个模型提供一些参考。

3.2.1 逻辑回归模型

逻辑回归模型的核心原理与数学公式详见 2.2.1.1 节。把逻辑回归作为本研究的基准模型，原因有几个。它结构简单，训练速度非常快，很快就能跑出一个基线性能，后面的模型可以拿这个基线做参照。其他模型跟逻辑回归一比，不同算法提升了多少就清楚了。逻辑回归也比较好解释，模型系数能直接看出每个特征对流失风险的影响方向和大小：系数为正，说明该特征值越大，用户流失风险越高；为负则相反。这个解释性对后续分析流失原因、制定挽留策略有帮助。另外，逻辑回归拟合线性关系的能力不错，能抓住特征和流失风险之间的线性部分。电信用户数据里确实有很多非线性关系，但线性关系同样是流失行为的一部分，逻辑回归在这方面能发挥作用。

3.2.2 支持向量机模型

支持向量机的核心原理和数学公式在 2.2.1.2 节已有说明。我们将其选为补充对比模型，主要考虑两点：一是在高维特征空间里分类表现较好，特征维度比样本数量多的情况也能处理。电信用户数据经过特征工程后，特征维度可能明显增加，支持向量机在这种条件下依然能保持不错的分类能力。二是通过核函数，支持向量机可以把低维线性不可分的数据映射到高维线性可分的空间，从而处理非线性分类问题。不同的核函数适应不同类型的数据分布，灵活度比较高。

3.2.3 随机森林模型

随机森林的核心原理和数学公式在 2.2.1.3 节已经讲过。之所以把它选为中等复杂度的对比模型，主要是看中它对噪声数据比较抗造。电信用户数据里难免有些噪声，比如用户偶尔的消费波动、异常通话记录、缺失的特征值等。随机森林用多棵决策树投票，能减小噪声对预测结果的影响，模型也更稳一些。另外，随机森林能自动处理特征之间的非线性关系和高阶交互，不用做太复杂的特征工程。电信用户数据里，特征之间的关系常常很复杂，像消费金额和上网时长的交互、流量使用量和套餐类型的交互等，随机森林自己就能捕捉到这些关系，不需要人工去设计交互特征。还有，随机森林可以输出特征重要性排序，从而看出哪些特征对用户流失影响大。分析这些特征，就能知道哪些因素最值得关注，后续做特征工程或者调整业务策略就有了方向。

3.2.4 梯度提升树模型

梯度提升树模型的核心原理与数学公式详见 2.2.1.4 节。选择传统梯度提升树作为集成学习模型的基线，是因为它是集成学习算法的基础，XGBoost、LightGBM、CatBoost 等高性能集成算法均是在传统梯度提升树的基础上发展而来的。通过对比传统梯度提升树与改进型梯度提升算法的性能，可以直观地量化各项改进技术的实际效果。同时，梯度提升树在结构化数据分类任务中表现出优异的预测能力，能够有效捕捉特征之间的复杂非线性关系，虽然其性能不如后续的改进型算法，但仍然是一种非常有效的分类方法，能够为模型性能对比提供重要的参考。

3.3 集成学习模型分支设计

集成学习把多个基学习器的优势合在一起，预测精度和泛化能力通常比单一模型更高。现在做结构化数据分类任务，集成学习用得也比较多。本研究选

了 XGBoost、LightGBM、CatBoost 三种主流的梯度提升集成算法作为核心模型。这三种算法都针对传统梯度提升树的不足做了优化，跟电信客户流失预测这个任务的特点更贴合。

3.3.1 XGBoost 模型

XGBoost 的核心原理和改进机制在 2.2.2.1 节已经讲述。XGBoost 在目标函数里加了 L1 和 L2 正则化项，这样能控制模型复杂度，降低过拟合的风险。电信客户流失预测里样本不平衡比较严重，模型容易偏向多数类并出现过拟合，XGBoost 的正则化机制正好能缓解这个问题。另外，XGBoost 支持特征粒度的并行计算，训练速度比传统梯度提升树快了不少。传统 GBDT 是串行训练，速度慢；XGBoost 在训练前先把特征排序好，存成块结构，节点分裂时可以并行计算所有特征的分裂增益，训练时间就短了。还有，XGBoost 自己带了缺失值处理机制，能自动学习缺失值往哪边分最好，不用提前做复杂的缺失值填充。电信用户数据里经常缺值，XGBoost 这个特性可以省掉一些预处理步骤，也避免了人工填充可能带来的误差。

3.3.2 LightGBM 模型

LightGBM 算法的核心原理与改进机制详见 2.2.2.2 节。选择 LightGBM 作为本研究的核心模型之一，首先是因为其采用直方图算法将连续型特征离散化为有限个直方图区间，通过计算每个区间的统计量来寻找最优分裂点。这一方法大幅减少了计算量和内存占用，使得模型能够高效处理百万级别的电信用户数据。同时，LightGBM 采用按叶子生长的策略替代了传统的按层生长策略，每次只分裂增益最大的叶子节点。这种策略能够在相同迭代次数下得到更低的损失值，提升模型的预测精度，同时进一步缩短训练时间。此外，LightGBM 原生支持类别特征处理，无需进行人工编码。电信用户数据中包含大量的类别特征，如套餐类型、付款方式、归属地等，传统算法需要将这些特征转换为数值型才能进行处理，而 LightGBM 能够直接处理类别特征，简化了特征工程流程。

3.3.3 CatBoost 模型

CatBoost 算法的核心原理与改进机制详见 2.2.2.3 节。选择 CatBoost 作为核心模型之一，原因有几个。它用目标编码来自动处理类别特征，把类别特征转换成带统计意义的数值型。跟传统的独热编码、标签编码比起来，目标编码能更好地保留类别特征的信息，也不会造成维度灾难。在此基础上，CatBoost 还引入了排序提升机制，通过随机打乱样本顺序来避免梯度偏差。传统梯度提升算

法在算残差时用的是同一份训练数据，容易过拟合，排序提升机制能缓解这个问题，让模型泛化能力更好。同时，CatBoost 采用有序提升策略，每训练一棵决策树都用不同的样本排列，进一步减少过拟合的风险。CatBoost 也支持自动处理缺失值，不用提前做填充，数据预处理能省不少事。

3.4 模型训练与验证流程

为保证所有模型在相同的条件下进行训练和评估，确保实验结果的公平性和可复现性，本研究设计了标准化的模型训练与验证流程，所有模型均遵循相同的流程进行训练和验证，流程的每一个环节都进行了明确的定义和规范。标准化模型训练与验证流程如图 3-2 所示。




图 3-2 标准化模型训练与验证流程

Figure 3-2 Standardized model training and validation process

注：LightGBM 和 CatBoost 模型采用 20 轮早停机制，其余模型完整执行预设迭代次数

3.4.1 配置加载与数据校验

流程的第一步是加载实验参数配置表，获取模型类型、超参数范围、验证方式、结果保存路径等所有实验配置。所有配置均集中管理，模型核心逻辑不包含任何硬编码的参数，确保实验的可复现性。

配置加载完成后，输入层对传入的特征矩阵和标签向量进行格式和维度校验，确保数据符合模型训练的基本要求。如果校验不通过，流程将终止并提示错误信息，避免因数据格式错误导致的训练失败。

3.4.2 模型初始化与数据划分

根据实验参数配置中的模型类型和初始超参数，初始化对应的模型实例。所有模型均遵循统一的调用规范，确保后续的训练和验证流程能够以相同的方式调用不同的模型。

模型初始化完成后，将输入的训练集进一步划分为训练子集和验证子集。划分采用分层随机抽样的方式，保证训练子集和验证子集中正负样本的比例与原始训练集一致，避免因数据分布不均导致的评估结果偏差。本研究采用 5 折分层交叉验证，在保证评估结果可靠性的同时兼顾计算效率。

3.4.3 模型训练与早停机制

将训练子集输入模型进行迭代训练，每迭代训练一轮后，在验证子集上评估模型的性能。如果当前轮次的验证集性能优于之前的最优性能，则更新最优性能并保存当前的模型参数；如果验证集性能没有提升，则将早停计数器加 1。

当早停计数器达到预设的阈值时，说明模型性能已经不再提升，流程将提前停止训练，防止过拟合。本研究为 LightGBM 和 CatBoost 设置连续 20 轮迭代性能无提升时触发早停机制，XGBoost 和所有传统机器学习模型则完整执行预设的迭代次数，以对比不同训练策略对模型性能的影响。

3.4.4 结果输出

训练结束后，加载验证集性能最优的模型参数，生成最终的预测结果。输出层将预测标签、流失概率、最优模型参数、特征重要性信息和训练过程性能数据以标准化的格式进行保存，为后续的实验分析和多模型对比提供数据支持。

3.5 本章小结

本章详细阐述了基于集成学习的电信客户流失预测模型的设计与实现。首先介绍了模型的整体设计思路和三模块整体框架，详细说明了数据预处理与特征工程、模型训练与验证、模型指标输出三个核心模块的功能与设计逻辑；然后分别阐述了传统机器学习模型分支和集成学习模型分支的设计思路，以及每个模型的选择依据；最后设计了标准化的模型训练与验证流程，确保实验结果的公平性和可复现性。

本章设计的模型框架融合了传统机器学习算法和集成学习算法的优势，通过多模型对比能够全面评估不同算法在电信客户流失预测任务中的性能表现。框架采用模块化和标准化的设计，具有较强的可扩展性和可维护性，为后续的

实验验证提供了坚实的技术基础。第 4 章将基于本章设计的模型框架，针对电信客户流失预测的具体任务，开展实验设计、数据处理、模型训练与结果分析。

第4章.实验结果与分析

本章先介绍实验环境与模型参数配置以及模型评估指标，接着进行数据预处理与特征工程构建。然后围绕基于集成学习的电信客户流失预测模型，做几组对比实验：传统基线模型对比、集成基线模型对比、三个高性能梯度提升模型对比。先介绍软实验环境，再说各组实验的结果和表现，最后综合对比分析，选出最优模型。

4.1 实验环境与模型参数配置

4.1.1 实验环境

本文的实验环境配置如下：

- 1.操作系统：Windows 11；
- 2.开发语言：Python 3.10；
- 3.核心依赖库：Pandas 1.5.3、NumPy 1.24.3、Scikit-learn 1.2.2、XGBoost 1.7.5、LightGBM 3.3.5、Matplotlib 3.7.1、Seaborn 0.12.2；
- 4.硬件环境：Intel Core i7-12700H 处理器，16GB 运行内存。

4.1.2 模型超参数配置

本文所有模型采用统一的超参数配置，具体参数如表 4-1 所示。

表 4-1 参数配置

Table 4-1 Parameter configuration

模型名称	核心超参数配置
逻辑回归	最大迭代次数 = 1000，L2 正则化，随机种子 = 42
SVM 支持向量机	RBF 核函数，开启概率预测，随机种子 = 42
梯度提升 (GBDT)	迭代次数 = 100，最大深度 = 5，学习率 = 0.1，子采样率 = 0.8，随机种子 = 42
随机森林	决策树数量 = 200，最大深度 = 10，最小分裂样本数 = 5，随机种子 = 42
XGBoost	迭代次数 = 200，最大深度 = 6，学习率 = 0.1，子采样率 = 0.8，随机种子 = 42

模型名称	核心超参数配置
LightGBM	迭代次数 = 200, 最大深度 = 6, 学习率 = 0.1, 子采样率 = 0.8, 随机种子 = 42
CatBoost	迭代次数 = 200, 最大深度 = 6, 学习率 = 0.1, 随机种子 = 42

4.2 模型评估指标

电信用户流失预测这个任务，样本本来就不平衡。所以光看一个指标不够，得用几个指标一起衡量模型好不好。本文用了混淆矩阵、准确率、精确率、召回率、F1 值，还有 AUC 值^[36]。这里面，最核心的指标是 AUC 值。AUC 值不受样本不平衡的影响，能客观反映模型区分正负样本的能力。AUC 值越高，说明模型越靠谱。

4.2.1 混淆矩阵

混淆矩阵是分类任务中用于评估模型性能的核心工具，以二维表格的形式呈现模型预测结果与样本真实标签的对应关系，清晰展示模型对不同类别的区分能力^[37]。其基本结构如下表 4-2 所示：

表 4-2 混淆矩阵
Table 4-2 Confusion Matrix

实际标签\预测标签	预测为正例	预测为负例
实际为正例	TP (真正例)	FN (假负例)
实际为负例	FP (假正例)	TN (真负例)

先阐述混淆矩阵里字母的意思：

TP：用户实际会流失，模型也预测会流失（预测准确）

FN：用户实际会流失，模型预测不会流失（预测错误）

FP：用户实际不会流失，模型预测会流失（预测错误）

TN：用户实际不会流失，模型也预测不会流失（预测准确）

根据混淆矩阵可算出评价指标，如准确率、精确率、召回率、F1 值等^[38]。

（1）准确率（Accuracy）：模型正确预测的样本占总样本的比例：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.1)$$

（2）精确率（Precision）：预测为流失用户的样本中，真实流失用户的比例：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4.2)$$

（3）召回率（Recall）：真实流失用户中，被模型正确识别的比例：

$$\text{Recall} = \frac{TP}{TP + FN} \quad (4.3)$$

(4) F1 值：精确率与召回率的调和平均数，综合衡量模型性能：

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4.4)$$

4.2.2 ROC 曲线与 AUC 值

精确率、召回率等单一评价指标只能从单一维度衡量模型分类效果，且未兼顾负样本的判别情况，存在评价视角片面的问题。为此本文引入 ROC 曲线与 AUC 值，从全局角度综合评价二分类模型的整体性能^[39]。

ROC 曲线是以假正例率 **FPR** 为横坐标、真正例率 **TPR** 为纵坐标绘制的性能曲线。

其中，真正例率计算公式为：

$$TPR = \frac{TP}{TP + FN} \quad (4.5)$$

TPR 反映所有真实正样本中被模型正确识别的比例，数值越高，说明模型对流失正样本的识别能力越强，漏判情况越少。

假正例率计算公式为：

$$FPR = \frac{FP}{FP + TN} \quad (4.6)$$

FPR 代表真实负样本中被误判为正样本的比例，该值越小，模型对负样本的错判概率越低。

绘制 ROC 曲线时，首先将模型输出的样本预测概率按大小排序，通过不断调整分类阈值，分别计算每一阈值对应的 **TPR** 和 **FPR**，以坐标点形式拟合得到完整曲线。当分类阈值最小时，全部样本被判定为正类，**TPR**、**FPR** 均为 1；当分类阈值最大时，所有样本均判定为负类，**TPR**、**FPR** 均为 0。

AUC 值为 ROC 曲线下包围的面积，取值范围介于 0~1 之间，如图 2。其物理意义可解释为：随机选取一个正样本和一个负样本，模型给出正样本预测概率大于负样本的概率。ROC 曲线越靠近坐标左上角，模型分类性能越优，对应的 **AUC** 值也越大。




图 4-1 ROC 曲线与 AUC 值
Figure 4-1 ROC curve and AUC value

$AUC = 1$ 代表模型达到理想分类效果； $AUC = 0.5$ 表示模型分类能力等同于随机猜测； AUC 小于 0.5 则说明模型判别效果劣于随机划分。

在电信用户流失这类样本不均衡场景下， AUC 指标不受正负样本比例差异影响，能够客观反映模型整体区分能力。同时 ROC 曲线可视化程度高，可直观对比随机森林、GBDT、XGBoost、LightGBM、CatBoost 多种模型的综合性能，因此本文将 ROC 曲线与 AUC 值作为重要评估依据^[40]。

4.3 数据预处理和特征工程

4.3.1 数据集说明及数据预处理

4.3.1.1 数据集说明

本文用的数据来自某电信运营商，是真实的用户业务数据。里面包含用户消费、业务使用、粘性绑定等多个维度的行为特征。要预测的目标是用户到底会不会离网。

数据集分了两部分：一部分是带真实标签的训练集，另一是独立测试集（不带标签）。训练集用来训练和验证模型，独立测试集最后用来生成预测结果。

数据的基本情况如下：

1. 训练集有 12000 条用户记录。其中流失用户大概占了 16.67%，样本不平衡问题比较明显。

2. 测试集有 3000 条，数据结构和训练集一样。

3. 原始特征有 30 多个，覆盖了用户活跃度、流量使用、通话行为、消费能力等方面。

因为项目给的独立测试集没有真实标签，没法直接算模型性能。所以本文用了训练集、验证集、测试集三级划分的方式，这是机器学习实验的常规做法。具体规则如下：

1. 分层抽样划分：把带标签的原始训练集按 8 比 2 的比例，用分层随机抽样的方法分成训练集和验证集。这样能保证两个集里流失用户和留存用户的比例和原始数据集完全一样，避免因数据分布变化导致评估不准。

2. 各集分工：

- (1) 训练集（80%）：让模型学习用户离网的规律，用来拟合模型参数。

- (2) 验证集（20%）：有真实标签，不参与训练。用来评估模型的泛化能力、调超参数、对比模型性能、筛选最优模型。

- (3) 独立测试集：不参与任何训练和验证。只在最优模型训练完后，拿来生成最终的离网预测结果，作为项目要交付的输出。

本文没有对不平衡样本做任何过采样、欠采样之类的处理，保持了数据的原始分布。这样做是为了让实验结果更真实、更贴合业务场景。

4.3.1.2 数据预处理

为降低缺失值、异常值、特征尺度不一、类别不统一及样本分布不平衡对模型训练造成的不利影响，在模型训练开始前必须对原始数据进行系统化、规范化的预处理。

本文所使用的电信数据集具有维度高、类型复杂、数值范围差异大、缺失率不均等特点，若直接输入模型将导致收敛困难、梯度爆炸、泛化性能下降等问题，且模型输入层通常要求统一格式的特征输入。因此，本章设计了一套完整、稳健、无数据泄露的数据预处理流程。

为增强模型泛化能力，使模型在用户行为波动、环境变化及特征分布偏移情况下仍能稳定识别流失风险，本文采用对数值特征与类别特征采用差异化处理方式，保证数据分布不变、业务逻辑一致。错误!未找到引用源。

本文数据预处理流程如下：

- 1.数据加载与初步探查：读取训练集与测试集，统计样本量、特征维度与流失标签分布，明确不平衡比例；
- 2.特征类型自动识别：自动区分数值型特征与类别型特征，为后续差异化处理提供依据；
- 3.缺失值处理：数值型特征采用训练集中位数填充，类别型特征采用训练集众数填充，提升鲁棒性；
- 4.类别特征编码：采用标签编码将文本类别映射为数值，并对未知类别做兼容处理；
- 5.标签标准化：将原始标签统一映射为 1=流失、0=留存，与模型优化目标保持一致。

经过预处理后，数据噪声显著降低，特征格式统一，为后续特征工程与模型训练提供了高质量数据基础。

4.3.2 特征工程构建与特征分析

特征工程这一步是关键，流失用户能不能被准确识别出来，很大程度就看特征做得好不好。本文结合电信用户流失的业务逻辑，再看用户流失前通常会有什么行为变化，构造了三类衍生特征：时序异动特征、高风险识别特征、用户画像特征。这样做是为了把原始数据里能预示流失的信号尽量挖出来。后面还做了特征可视化和相关性分析，来看这些特征到底是否有作用。

4.3.2.1 时序异动特征

用户离网前通常会出现行为的显著异动，本文基于当月、上月、近 3 个月的时序数据，构建行为变化类特征，捕捉用户离网前的行为萎缩信号：

- 1.活跃度异动特征：基于当月活跃天数与上月活跃天数，构建活跃天数变化量 ACT_DAYS_CHANGE、活跃天数环比 ACT_DAYS_RATIO，刻画用户活跃度的骤降趋势；

2.流量使用异动特征：基于当月流量使用量与上月流量使用量，构建流量变化量 DS_VOL_CHANGE，捕捉用户流量使用的大幅下滑行为；

3.通话行为异动特征：基于当月通话次数与近 3 个月平均通话次数，构建通话次数比率 CALL_CNT_RATIO，识别用户通话行为的萎缩趋势；

4.消费能力特征：基于近 3 个月累计缴费金额，构建月均消费特征 AVG_MONTHLY_PAY，刻画用户的长期消费能力与消费变化趋势。

4.3.2.2 高风险识别二值特征

基于电信运营的业务经验，直接将经过行业验证的离网强信号转化为高区分度的二值特征，大幅提升模型对流失用户的识别能力：

1.低活跃用户特征 IS_LOW_ACTIVE：当月活跃天数 ≤ 5 天的用户标记为 1，这类用户几乎无业务使用行为，离网意愿极强；

2.零通话用户特征 IS_LOW_CALL：当月通话次数为 0 的用户标记为 1，这类用户已基本停止使用核心通信服务，是离网高风险群体；

3.低粘性用户特征 IS_LOW_STICKY：仅绑定 1 个号码的用户标记为 1，这类用户无家庭宽带、多号码绑定等粘性业务，转网成本极低，离网风险显著高于多号码绑定用户。

4.3.2.3 用户画像统计特征

从消费能力、业务使用、粘性绑定多个维度，构建用户的全维度画像特征，丰富模型对用户在网上粘性的刻画：

1.通话质量特征：基于当月通话时长与通话次数，构建平均单次通话时长 AVG_CALL_DUR，刻画用户的通话业务使用深度；

2.全业务活跃度特征：基于移动业务活跃天数与宽带业务活跃天数，构建总活跃天数 TOTAL_ACT_DAYS，刻画用户全业务的在网上粘性；

4.3.2.4 特征可视化与相关性分析

为验证特征工程的有效性，本文通过特征相关性热力图与模型特征重要性排序图，从特征间相关性、特征对目标的贡献度两个维度进行可视化分析。

（1）特征相关性热力图分析

绘制了衍生特征之间的相关性热力图，分析特征间的多重共线性问题。从热力图 4-2 中可以看出：

1.活跃天数变化量（ACT_DAYS_CHANGE）、活跃天数环比（ACT_DAYS_RATIO）、总活跃天数（TOTAL_ACT_DAYS）等活跃度衍生特征之间存在较强的相关性，符合业务逻辑；

2.低活跃用户（IS_LOW_ACTIVE）与零通话用户（IS_LOW_CALL）两个高风险特征之间呈现较强的正相关，说明两类用户的离网风险具有高度一致性；

3.整体来看，大部分衍生特征之间的相关性处于合理区间，未出现严重的多重共线性问题，保证了后续模型训练的稳定性。




图 4-2 衍生特征相关性热力图

Figure 4-2 Heat map of derived feature correlation

(2) 模型特征重要性分析

为了验证我们做的衍生特征到底对预测离网有没有用，本文拿训练好的六个模型（逻辑回归、随机森林、梯度提升树、XGBoost、LightGBM、CatBoost），分别画了它们各自排名前 20 的特征重要性图。从图 4-3 的结果能看出下面几点：

1.我们构造的活跃度异动特征（ACT_DAYS_RATIO）和用户画像特征（AVG_CALL_DUR），在好几个模型里都进了前 20。高风险二值特征（IS_LOW_CALL）在逻辑回归模型里也比较靠前。这说明这些衍生特征确实能帮助预测用户会不会离网。

2.不同模型排在前面的最重要特征，重合度还挺高的。意思就是这些特征预测离网的能力比较稳定，换个模型也能用，不会因为模型选的不一样就变。

3.一些跟消费挂钩的特征（比如 R3_FIN_AMT），还有跟业务使用时长相关的特征（比如 PROM_TO_2_VS_DUR），也在多个模型里排得比较靠前。这些跟电信用户流失的业务逻辑也对得上。




图 4-3 多模型特征重要性对比

Figure 4-3 Comparison of feature importance among multiple models

上述可视化结果验证了本文构建的特征工程体系的有效性，为后续模型训练与优化提供了可靠的特征基础。

4.4 实验结果对比分析

4.4.1 传统机器学习基线模型结果分析

本节以逻辑回归、支持向量机（SVM）、随机森林、梯度提升树（GBDT）作为传统机器学习模型，如图 4-4，4-5，4-6，4-7。

逻辑回归的整体准确率为 0.4296，ROC-AUC 为 0.7070。模型对流失用户的召回率达到 0.8425，但精确率仅 0.2051，存在大量误判，无法满足精准预测需求。




图 4-4 逻辑回归混淆矩阵
Figure 4-4 Confusion matrix of logistic regression

SVM 的准确率为 0.7638，ROC-AUC 为 0.7066，整体预测稳定性更好，但流失用户召回率仅 0.4950，对少数类的识别能力不足。




图 4-5 SVM 混淆矩阵

Figure 4-5 Confusion matrix of SVM

随机森林的准确率为 0.6408，ROC-AUC 为 0.7254，召回率为 0.7075，相比传统模型有明显提升，但精确率仅 0.2753，误判依然偏高。




图 4-6 随机森林混淆矩阵

Figure 4-6 Confusion matrix of Random Forest

GBDT 的准确率为 0.8187，ROC-AUC 为 0.7318，整体预测一致性更强，但对流失用户的召回率仅 0.4300，覆盖度不足。




图 4-7 GBDT 混淆矩阵

Figure 4-7 Confusion matrix of GBDT

逻辑回归、支持向量机（SVM）两类传统模型受限于线性结构，难以充分学习特征间的非线性关系，在不平衡数据集上表现有限，仅作为基础对比基准。

随机森林、梯度提升树（GBDT）优于逻辑回归、支持向量机（SVM），但在精确率与召回率之间仍未达到理想平衡，存在明显优化空间。

4.4.2 集成学习模型结果分析

本节重点分析 XGBoost、LightGBM、CatBoost 三类高性能梯度提升集成模型，混淆矩阵如图 4-8，图 4-9，和图 4-10。

XGBoost: 准确率 0.8525（全场最高），ROC-AUC 值 0.7410（全场最高），精确率 0.6825（全场最高），对在网用户识别准确率达 98%，整体稳定性与判别能力最强。




图 4-8 XGBoost 混淆矩阵
Figure 4-8 Confusion matrix of XGBoost

LightGBM: 准确率 0.7762，ROC-AUC 值 0.7234，召回率 0.5375，训练效率高，泛化性能均衡。




图 4-9 LightGBM 混淆矩阵
Figure 4-9 Confusion matrix of LightGBM

CatBoost: 准确率 0.7529，ROC-AUC 值 0.7353，召回率 0.5750，在三类模型中召回率最优，对流失用户覆盖度更高。




图 4-10 CatBoost 混淆矩阵

Figure 4-10 Confusion matrix of CatBoost

三类模型均显著优于基线模型，各自在精度、效率、覆盖率上具备不同优势。

4.4.3 多模型综合对比分析

为了让不同模型的表现一目了然，本文把 7 个模型的准确率、精确率、召回率、F1 分数和 ROC-AUC 都汇总到了表 4-1 里。整体上看，性能分层很明显：高性能梯度提升模型最好，集成学习基线模型次之，传统机器学习基线模型最差。

表 4-3 各模型性能指标对比表

Table 4-3 Comparison of performance indicators of each model

模型名称	准确率	精确率	召回率	F1 分数	ROC-AUC
逻辑回归	0.4296	0.2051	0.8425	0.3299	0.7070
SVM	0.7638	0.3517	0.4950	0.4112	0.7066
随机森林	0.6408	0.2753	0.7075	0.3964	0.7254
GBDT	0.8188	0.4538	0.4300	0.4416	0.7318
XGBoost	0.8525	0.6825	0.2150	0.3270	0.7410
LightGBM	0.7762	0.3792	0.5375	0.4447	0.7234
CatBoost	0.7529	0.3522	0.5750	0.4368	0.7353




图 4-11 各模型性能指标与 ROC 曲线对比

Figure 4-11 Comparison of performance indicators and ROC curves of each mode

从表 4-3 及图 4-11 可以清晰看出：

1. ROC-AUC 排名：XGBoost (0.7410) > CatBoost (0.7353) > GBDT (0.7318) > 随机森林 (0.7254) > LightGBM (0.7234) > 逻辑回归 (0.7070) > SVM (0.7066)。XGBoost 的 ROC-AUC 最高，表明其对正负样本的区分能力最强；
2. 准确率排名：XGBoost (0.8525) > GBDT (0.8188) > LightGBM (0.7762) > SVM (0.7638) > CatBoost (0.7529) > 随机森林 (0.6408) > 逻辑回归 (0.4296)。XGBoost 在整体预测正确性上表现最优；
3. 精确率排名：XGBoost (0.6825) 远高于其他模型，说明其预测为流失的用户中真实流失比例最高，误判率最低，最适合业务落地；
4. 召回率：CatBoost (0.5750)、LightGBM (0.5375)、SVM (0.4950) 表现较好，能够识别出更多流失用户。

综合 ROC-AUC、准确率、精确率、模型稳定性四项关键指标，XGBoost 模型综合表现最优，因此本文将 XGBoost 作为电信客户流失预测的最优模型。

4.5 本章小结

本章首先明确了实验软硬件环境与各模型统一超参数配置，针对电信数据集样本不均衡特点，选取混淆矩阵、准确率、精确率、召回率、F1 值及 ROC-AUC 作为综合评估指标。随后完成数据集划分、数据预处理与特征工程工作，结合电信业务场景构建时序异动、高风险识别及用户画像三类衍生特征，并通过相关性热力图与特征重要性分析，验证了所构建特征体系的合理性与有效性。

在此基础上，本章依次开展传统机器学习、集成基线模型及高性能梯度提升模型的对比实验，从分类效果、拟合能力及泛化性能多角度进行分析。实验结果表明，集成学习模型整体性能优于传统机器学习模型，其中 XGBoost 在准确率、精确率与 ROC-AUC 指标上均表现最优，样本区分能力强、误判率低，更适配电信客户流失预测的实际业务需求。本章实验流程严谨、对比维度完整，充分验证了本文数据预处理方案、特征工程构造思路及梯度提升模型在流失预测任务中的可行性与优越性，可为电信运营商挖掘潜在流失用户、制定客户留存策略提供技术依据与参考。

第 5 章.结论与展望

5.1 结论

本文围绕电信客户流失预测任务，搭建了一套用集成学习的完整预测体系，从头到尾覆盖了数据预处理、特征工程、模型构建直到业务应用的全部流程，做多组对比实验验证了这套方案是有效的。

针对电信用户数据本身特点设计了标准化预处理流程，做了缺失值填充、异常值剔除、类别特征编码这些操作，有效提高了数据质量，给后面的模型训练打好了基础。

围绕业务逻辑搭建出来的衍生特征体系效果很明显，活跃天数、活跃度环比这类特征，在特征重要性排名里排在前面，这也能证明贴合业务场景做特征工程，确实能有效提高模型的判别能力。经过特征重要性分析发现，用户活跃度、业务使用强度和用户粘性，是影响用户流失的三个核心因素，这些结论可以给运营商优化运营工作给出数据支撑。

实验结果表明，集成学习模型的综合性能明显比传统机器学习模型好，其中 XGBoost 模型表现得最好，在验证集上拿到了 0.853 的准确率、0.683 的精确率还有 0.741 的 AUC 值，泛化能力是最强的，最适合用在电信用户流失预警场景里。受数据集本身类别不平衡的影响，模型整体的召回率偏低，这个结果跟真实业务的规律是吻合的。

5.2 研究不足与未来展望

受研究时间还有现有数据条件的限制，本文还存在不少需要完善的地方，之后还可以从好几个方面继续优化。

本文没有针对电信数据本身就带有的样本不平衡问题做专门处理，这就导致模型识别流失用户的能力还有待提高。后续可以加入 SMOTE 过采样、类别权重调整这类办法，优化模型对少数类样本的学习效果，进一步提高流失用户的召回率。

现在搭建的特征体系，主要是用了用户的截面行为快照数据，没能把用户行为在时间上的变化规律挖透，也没有加入外部数据。之后研究可以补上用户消费、通话还有流量使用的时序特征，再把网络质量、区域市场竞争情况这些多来源的外部信息结合进来，丰富特征维度，提高预测的准确度。

本文只对比了传统机器学习和梯度提升集成算法，没有去试深度学习在结构化数据分类里的应用，模型融合的方法也比较简单，后面可以试着加入 TabNet、FT-Transformer 这类适合表格数据的深度学习模型，再用 Stacking 这类更复杂的融合策略，进一步挖出模型性能的上限，后续研究还可以结合因果推

断方法，分析不同挽留策略实际能起到的效果，做到从“预测谁会流失”到“该对谁用什么样的精准干预”的升级，让模型输出对业务更有指导意义。未来还可以把模型放到实际运营系统里用，搭好端到端的用户流失预警平台，再通过真实业务场景里的 A/B 测试不断完善迭代模型，促进技术和业务更深层次地融合，真正让预测模型在运营商客户关系管理里发挥作用。

参考文献

- [1] Chang V ,Hall K ,Xu A Q , et al. Prediction of Customer Churn Behavior in the Telecommunication Industry Using Machine Learning Models [J].Algorithms,2024,17 (6):231-.DOI:10.3390/A17060231.
- [2] Sana K J ,Rahman S M ,Rahman S M . Privacy-preserving customer churn prediction model in the context of telecommunication industry [J].Engineering Applications of Artificial Intelligence,2025,162 (PD):112514-112514.DOI:10.1016/J.ENGAPPAI.2025.112514.
- [3] Asif D ,Arif S M ,Mukheimer A . A data-driven approach with explainable artificial intelligence for customer churn prediction in the telecommunications industry [J].Results in Engineering,2025,26104629-104629.DOI:10.1016/J.RINENG.2025.104629.
- [4] 阿克弘, 胡晓东。基于 GAN 数据重构的电信用户流失预测方法 [J]. 电信科学, 2023,39 (03):135-142.
- [5] 胡晓东, 吕铭春, 阿克弘, 等。基于优化 XGBoost 算法的电信用户流失预测 [J]. 科技与创新, 2024,(10):36-39+44.DOI:10.15913/j.cnki.kjycx.2024.10.007.
- [6] Haridasan V ,Hariharanath K ,Muthukumaran K . Gazelle optimization and conditional variational auto encoder for telecom user service recommendation based on churn analysis [J].Expert Systems With Applications,2025,267126199-126199.DOI:10.1016/J.ESWA.2024.126199.
- [7] Omid G S ,Hossein M R . Ensemble classification using balanced data to predict customer churn: a case study on the telecom industry [J].Multimedia Tools and Applications,2023,83 (15):44799-44831.DOI:10.1007/S11042-023-17267-9.
- [8] Hamza U E F ,Balogun O A ,Amosa T R , et al. Sampling-based novel heterogeneous multi-layer stacking ensemble method for telecom customer churn prediction [J].Scientific African,2024,24e02223-.DOI:10.1016/J.SCIAF.2024.E02223.
- [9] Googerdchi F K ,Asadi S ,Jafari M S . Customer churn modeling in telecommunication using a novel multi-objective evolutionary clustering-based ensemble learning.[J].PloS one,2024,19 (6):e0303881-e0303881.DOI:10.1371/JOURNAL.PONE.0303881.
- [10] Abdelhady G M ,Mohamed A K . Leveraging artificial intelligence for predictive customer churn modeling in telecommunications: a framework for enhanced customer relationship management.[J].Scientific reports,2025,15 (1):43826-43826.DOI:10.1038/S41598-025-30108-Z.
- [11] Binh V T ,Thy G N. An application of rough set theory to predict telecom customer churn [J].International Journal of Computing Science and Mathematics, 2024,19 (3):274-284.DOI:10.1504/IJCSM.2024.137800.
- [12] Kirgiz B O ,Calli K M ,Cagliyor S , et al. Assessing the effectiveness of OTT services, branded apps, and gamified loyalty giveaways on mobile customer churn in the telecom industry: A machine-learning approach [J].Telecommunications Policy,2024,48 (8):102816-102816.DOI:10.1016/J.TELPOL.2024.102816.
- [13] Mettle A N H ,Osei G ,Winchester A E , et al. Enhancing Telecom Customer Churn Prediction Through Hyperparameter Tuning and Soft - Voting Ensemble

- le Modeling [J].Applied Computational Intelligence and Soft Computing,2026,2026 (1):7620084-7620084.DOI:10.1155/ACIS/7620084.
- [14] Ehsani F ,Hosseini M . Customer churn prediction using a novel meta-classifier: an investigation on transaction, Telecommunication and customer churn datasets [J].Journal of Combinatorial Optimization,2024,48 (1):7-7.DOI:10.1007/S10878-024-01196-W.
- [15] Wang C ,Rao C ,Hu F , et al. Risk assessment of customer churn in telco using FCLCNN-LSTM model [J].Expert Systems With Applications,2024,248123352-.DOI:10.1016/J.ESWA.2024.123352.
- [16] 黄学德,王磊,解姗姗,等。基于 XGBoost 和 SHAP 的电信用户流失影响因素分析 [J]. 电子技术, 2025,54 (12):66-68.
- [17] 元振锋,丁光宇,叶剑,等。融合逻辑回归与表格预训练模型的电信行业流失预警预测方法 [J]. 科学咨询, 2025,(02):17-19.
- [18] Saleh E M ,Alsabour A N . A novel systematic forest classifier for detecting client churn in the telecommunications industry [J].Discover Applied Sciences, 2026,8 (5):507-507.DOI:10.1007/S42452-026-08371-0.
- [19] Shimaa O ,T. K M ,A. M F A . A proposed hybrid framework to improve the accuracy of customer churn prediction in telecom industry [J].Journal of Big Data,2024,11 (1):DOI:10.1186/S40537-024-00922-9.
- [20] N M ,A V ,Chavva R S , et al. Prediction of User Attrition in Telecommunication Using Neural Network [J].EAI Endorsed Transactions on Scalable Information Systems,2024,11 (4):DOI:10.4108/EETSIS.5242.
- [21] 汪明达,周俏丽,蔡东风。采用混合模型的电信领域用户流失预测 [J]. 计算机工程与应用, 2019,55 (24):214-221+270.
- [22] 田波,沈江明,张浩。基于 Cox 模型的电信用户流失研究 [J]. 长江信息通信, 2021,34 (08):198-200.
- [23] 张三妞,张智斌。生存分析在电信客户流失中的应用 [J]. 现代电子技术, 2023,46 (12):84-90.DOI:10.16652/j.issn.1004-373x.2023.12.015.Ishaan Ganguwani, Sumedh Jadhav, Mustafa Saifee. CUSTOMER CHURN PREDICTION AND CATEGORIZATION A MACHINE LEARNING APPROACH[J]. International Journal of Advanced Research, 2025, 13(1).
- [24] 苏金树,张博锋,徐昕。基于机器学习的文本分类技术研究进展[J].软件学报, 2006, 17(9):12.DOI:CNKI:SUN:RJXB.0.2006-09-005.
- [25] 张轶。基于改进逻辑回归模型的数据预测与校验技术[J].信息技术, 2025 (5).
- [26] 覃木宝,王华,王龙林。基于改进海鸥算法优化支持向量机的斜拉桥索力优化研究[J].Forest Engineering, 2023, 39(4).DOI:10.3969/j.issn.1006-8023.2023.04.019.
- [27] 汪海燕,黎建辉,杨风雷。支持向量机理论及算法研究综述[J].计算机应用研究, 2014, 31(5):6.DOI:10.3969/j.issn.1001-3695.2014.05.001.
- [28] 王诚,赵晓培。基于混合采样的改进随机森林算法研究[J].计算机技术与发展, 2021, 31(12):6.DOI:10.3969/j.issn.1673-629X.2021.12.009.
- [29] Praful G K ,Hrushikesh N ,Mohanty B K .Environmental impact analysis and enhancement of factors affecting the photovoltaic (PV) energy utilization in mining industry by sparrow search optimization based gradient boosting decision tree approach[J].Energy,2022,244(PA):DOI:10.1016/J.ENERGY.2021.122561.
- [30] 韩笑,王新迎,韩帅,等。基于不均衡数据集成学习的大型电力变压器状态评

- 价方法[J].电网技术, 2021(001):045.
- [31] Hu R , Li Q , Qiu F .Ensemble Learning Based Convex Approximation of Three-Phase Power Flow[J].IEEE Transactions on Power Systems, 2021, PP(99): 1-1.DOI:10.1109/TPWRS.2021.3055481.
- [32] Chen T , He T , Benesty M .xgboost: Extreme Gradient Boosting[J]. 2016.
- [33] Chen Q ,Zhu L ,Yang D .An explainable photovoltaic power forecasting method for output based on multi-dimensional similarity game fusion and ISCSO-XGBoost[J].Applied Energy,2026,415127921-127921.DOI:10.1016/J.APENERGY.2026.127921.
- [34] Truong H V ,Nguyen T T T ,Thai T H , et al.Machine learning-based method using adaptive differential evolution for optimizing nonlinear steel frames[J].Structural and Multidisciplinary Optimization,2025,68(11):229-229.DOI:10.1007/S00158-025-04164-Y.
- [35] Wang H ,Huang L ,Wang Y .Bearing capacity prediction for pultruded GFRP short columns with I-section based on ensemble learning algorithm[J].Engineering Structures,2026,360122774-122774.DOI:10.1016/J.ENGSTRUCT.2026.122774.
- [36] 张冀豫,许家佗,屠立平,等.基于自适应权重多模态中西医数据融合方法的冠心病血管阻塞程度预测模型的构建与评价（英文）[J].Digital Chinese Medicine,2025,8(02):163-173.
- [37] 宋磊,王宝会,杜辉.基于三维 CT 切片的下肢骨分割算法的优化研究[J].计算机科学,2025,52(S2):408-414.
- [38] 刘峻晨.基于机器学习对县域地质灾害风险评价方法的研究[J].工程建设与设计,2025,(22):214-217.DOI:10.13616/j.cnki.gcjsysj.2025.11.270.
- [39] 胡荣.融合深度学习框架的通信安全态势感知技术[J].现代电子技术,2025,48(23):89-96.DOI:10.16652/j.issn.1004-373x.2025.23.013.
- [40] 袁程胜,姚梦非,李欣亭,等.多尺度分层级联网络的可泛化人脸活体检测[J].计算机系统应用,2025,34(12):192-205.DOI:10.15888/j.cnki.csa.010015.

致谢

四年过得真快，本科生涯就要结束了。毕设做完这一刻，我想对所有给过我指导、帮助和支持的老师、同学、家人，说一声谢谢。

首先要感谢我的指导老师暴琳老师，还有陈庆芳老师。从选题、理思路，到写论文、改论文，暴琳老师一直给我很细心的指导和耐心的帮助。暴琳老师治学很严谨，专业素养也深，做科研很务实，这些都让我学到很多，也给我以后的学习和工作树立了榜样。

还要感谢江苏科技大学教过我的各位任课老师。四年里你们的教导，帮我打下了扎实的专业基础，让我能顺利做完这次毕设的研究工作。同时也要谢谢我的同学和朋友们，学习和生活上给了我不少陪伴和帮助。和你们讨论交流，帮我拓宽了思路，很多难题也是在这些讨论中解决的。

最后要感谢我的父母和家人。你们无条件的支持、理解和鼓励，是我能安心念完书、做完研究的最强后盾。你们的陪伴，一直是我往前走的最大动力。

这次毕设是对我四年本科学习的一个总结，也是我未来职业生涯的一个起点。以后的日子里，我会继续保持严谨的学习态度和务实的工作作风，不断学，不断进步，不辜负学校和老师的培养和期望。